

Table des matières

1. NETTOYAGE ET VÉRIFICATION DES DONNÉES.....	1
2. ANALYSE EXPLORATOIRE	1
3. TRANSFORMATIONS ET CHOIX DES VARIABLES	3
4. SÉLECTION DU MODÈLE	3
MODÈLE 1 : MODÈLE COMPLET	4
MODÈLE 2 : MODÈLE COMPLET SANS LAT ($R^2_{\text{AJUSTÉ}} = 0.340$)	4
MODÈLE 3 : MODÈLE COMPLET SANS NET.AREA ($R^2_{\text{AJUSTÉ}} = 0.364$)	4
MODÈLE 4 : MODÈLE 3 SANS LON ET TIME ($R^2_{\text{AJUSTÉ}} = 0.276$)	5
MODÈLE 5 : MODÈLE 3 SANS TEMP.SURF ET TIME ($R^2_{\text{AJUSTÉ}} = 0.3019$)	5
MODÈLE 6 : MODÈLE 3 SANS TEMP.SURF ET S.DEPH ($R^2_{\text{AJUSTÉ}} = 0.3012$)	5
CONCLUSION SUR LA SÉLECTION DE MODÈLE	5
5. VALIDATION DU MODÈLE	5
6. INTERPRÉTATION ET CONCLUSION.....	6

Table des illustrations


<i>1- Histogrammes de la répartition de la densité des œufs et de son logarithme.....</i>	<i>1</i>
<i>2- Nuage de points avec les données brutes.....</i>	<i>2</i>
<i>3- Nuage de points avec la transformation en logarithme.....</i>	<i>2</i>
<i>4- Matrice de corrélation entre toutes les variables.....</i>	<i>3</i>
<i>5 - b.depth et log(b.depth).....</i>	<i>3</i>
<i>6 - Visualisation des résidus</i>	<i>5</i>
<i>7 - Distances de Cook.....</i>	<i>6</i>

1. NETTOYAGE ET VÉRIFICATION DES DONNÉES

Les données comprennent 369 observations et 11 variables. Aucune valeur manquante ni doublon n'a été détecté. Toutefois, l'analyse univariée révèle que la variable réponse, la densité des œufs (egg.dens), présente une distribution fortement asymétrique vers la droite (médiane = 31.02, moyenne = 65.67, max = 601.78). Cette structure nécessitera une transformation mathématique préalable à la régression afin de respecter les hypothèses de normalité et de stabilité de la variance. Une valeur extrême suspecte a aussi été relevée pour la variable flow (max = 305 938, min = 116, 3e quartile = 6291), dont l'influence sera évaluée lors de la validation du modèle.


2. ANALYSE EXPLORATOIRE

L'analyse exploratoire justifie définitivement la transformation logarithmique de la variable réponse (log_egg). D'une part, au niveau univarié, l'histogramme de la densité brute (egg.dens) montre une distribution fortement asymétrique vers la droite. L'application du logarithme corrige cette asymétrie pour offrir une distribution en cloche se rapprochant de la normalité.




1- Histogrammes de la répartition de la densité des œufs et de son logarithme

D'autre part, au niveau bivariée, les nuages de points initiaux formés avec la variable réponse sans transformation (egg.dens) démontrent que la densité brute génère une forte hétéroscédasticité, masquant les véritables tendances. L'utilisation du logarithme stabilise la variance et révèle des relations linéaires interprétables.



2- Nuage de points avec les données brutes




3- Nuage de points avec la transformation en logarithme

On observe une corrélation positive entre la densité transformée et les variables de profondeur (s.depth, $r = 0.38$; b.depth, $r = 0.26$). En revanche, les variables opérationnelles (time, flow, net.area) ont une faible corrélation ($r = 0.08$, $r = -0.11$, $r = 0.03$; respectivement) avec log_egg et ne présentent aucune structure linéaire évidente sur les nuages de points.

La matrice de corrélation met aussi en évidence une multicollinéarité que l'on ne peut ignorer entre la température en surface et celle à 20 mètres ($r = 0.94$), ce qui nécessitera le retrait d'une de ces variables avant la sélection du modèle pour garantir la stabilité des coefficients.

En se mettant dans le contexte de la biologie marine, l'on gardera la température de surface, puisque c'est là que les œufs de maquereau flottent la plupart du temps.


De plus, on observe de très fortes liaisons entre les variables spatiales et environnementales. lon est fortement corrélée à temp.surf ($r = 0.91$), temp.20m ($r = 0.85$) et s.depth ($r = -0.73$) et lat est corrélée à temp.surf ($r = -0.76$) et temp.20m ($r = -0.80$). Ces redondances seront quantifiées via le VIF en Partie 3.



4- Matrice de corrélation entre toutes les variables

3. TRANSFORMATIONS ET CHOIX DES VARIABLES

b.depth : Sur le nuage log_egg vs b.depth, les points sont entassés entre 0 et 500m, puis commencent à s'éparpiller jusqu'à 4450m. La transformation en logarithme de cette variable force les points à être mieux dispersés et à avoir une relation linéaire entre log(b.depth) et la variable réponse.



5 - b.depth et log(b.depth)

flow : On exclut la variable flow du modèle, car c'est une variable instrumentale et non un prédicteur biologique. Aussi elle a une faible corrélation ($r = -0.11$) avec la variable réponse.

temp.20m : On exclut cette variable, car elle a une forte corrélation avec temp.surf ($r = 0.94$). Justification biologique déjà faite.

4. SÉLECTION DU MODÈLE

Après la transformation et l'élimination manuelle de certaines variables, on se retrouve avec log_bdepth, lat, lon, time, s.depth, temp.surf, net.area et c.dist comme variables explicatives de log_egg : c'est notre modèle complet.

Modèle 1 : Modèle complet

L'algorithme Stepwise n'a retiré aucune variable. En effet, la première ligne « none », avec un AIC de 136.17, est la plus basse. L'algorithme a donc conclu que retirer n'importe quelle variable détériore le modèle. D'où la nécessité de calculer le VIF pour vérifier s'il y a des multicollinéarités cachées.

Les variables lon et temp.surf ont les VIF les plus élevés (9.478 et 8.242 respectivement). Elles sont redondantes et se battent pour la même information. Ce qui confirme le lien fort ($r = 0.91$) entre les deux ce qu'on avait vu dans la matrice de corrélation. Cependant selon l'algorithme de stepwise, lon est la variable la plus importante avec un AIC de 179.90 si on la retire et temp.surf est la seconde variable la plus importante avec un AIC de 155.59 quand on la retire. Le VIF seul ne suffit donc pas à décider du retrait d'une variable ; l'importance statistique (AIC) et le sens biologique doivent aussi être considérés.

On sait par contre que lon et temp.surf ont tous deux une forte corrélation avec lat et s.depth. La question n'est donc pas « *est-ce qu'on retire lon ou temp.surf ?* », mais « *est-ce que lat et s.depth apportent quelque chose qu'on ne capte pas déjà avec lon et temp.surf ?* ».

lat est corrélée à lon ($r = -0.74$) et à temp.surf ($r = -0.76$).

s.depth est corrélée à lon ($r = -0.73$) et à temp.surf ($r = -0.64$).

La variable lat est celle qui recopie le plus l'information de lon et temps.surf, on va donc la retirer pour tester le modèle 2.

Modèle 2 : Modèle complet sans lat ($R^2_{\text{ajusté}} = 0.340$)

La remarque la plus importante ici est la baisse du $R^2_{\text{ajusté}}$. Le premier modèle est donc meilleur à celui-là.

Retirer lat a légèrement réduit les VIF mais pas assez ; lon et temp.surf restent problématiques.

Une autre remarque est que net.area est aussi clairement non significatif dans les deux cas (valeur- $p_{\text{modèle1}} = 0.089$ et valeur- $p_{\text{modèle2}} = 0.846$).

Le retrait de lat était probablement une erreur. Comme troisième modèle, revenons au modèle complet, mais en retirant la variable net.area.

Modèle 3 : Modèle complet sans net.area ($R^2_{\text{ajusté}} = 0.364$)

On remarque une hausse du $R^2_{\text{ajusté}}$.

Par contre les VIF de lon et de temp.surf sont toujours aussi élevé. Les deux variables sont importantes, mais elles sont aussi problématiques. La logique est de retirer celle dont le VIF est le plus élevé, soit lon. Mais lon est aussi la plus importante selon l'AIC. On va donc tester les deux scénarios (sans lon et sans temp.surf) et comparer.

On retire aussi la valeur time, car elle est non significative (valeur- $p = 0.089$).

Modèle 4 : Modèle 3 sans lon et time ($R^2_{\text{ajusté}} = 0.276$)

Le VIF le plus élevé est 4.136, ce qui est largement mieux comparé aux modèles précédents. Mais on perd beaucoup d'informations en retirant cette variable. En effet, le $R^2_{\text{ajusté}}$ baisse d'environ 9 points comparé au modèle initial : ce modèle n'est pas efficace.

Modèle 5 : Modèle 3 sans temp.surf et time ($R^2_{\text{ajusté}} = 0.3019$)

On se retrouve dans la même situation qu'au modèle 4. Une baisse significative du $R^2_{\text{ajusté}}$ (baisse de 6 points) est synonyme de perte d'informations ; ce que l'on veut éviter. Cependant, l'on remarque dans le modèle 5 que toutes les variables sont significatifs, sauf s.depth (valeur- $p = 0.241$).

Étudions un sixième modèle, sans temps.surf et s.depth.

Modèle 6 : Modèle 3 sans temp.surf et s.depth ($R^2_{\text{ajusté}} = 0.3012$)

Ce modèle résout l'ensemble des problèmes diagnostiqués. Tous les VIF sont strictement inférieurs à 3, ce qui élimine la multicolinéarité présente dans les modèles précédents. De plus, toutes les variables conservées (log_bdepth, lat, lon, c.dist) sont fortement significatives (p -valeur < 0.05).


Conclusion sur la sélection de modèle

Le modèle 3 offrait le meilleur pouvoir explicatif ($R^2_{\text{ajusté}} = 0.364$), mais présentait une multicolinéarité importante ($VIF = 9.48$).

À l'inverse, le modèle 6 garantit la stabilité des coefficients. Bien que l'on observe une baisse du $R^2_{\text{ajusté}}$ (0.301), la rigueur mathématique impose de privilégier un modèle respectant les hypothèses de base. Le Modèle 6 est donc le modèle final retenu.

5. VALIDATION DU MODÈLE


Dans le graphique Q-Q des résidus pour le modèle choisi (6), les résidus standardisés de notre modèle épousent clairement la diagonale pour la plupart des valeurs. On peut observer toutefois une déviation vers le bas de la diagonale aux extrémités. Les queues de notre distribution sont donc un peu plus lourde que ceux d'une normale; on a un peu moins de valeurs extrêmes. En conclusion, l'hypothèse de normalité tient toujours après l'analyse du graphique Q-Q.



Dans le graphique des résidus selon la densité prédite par notre modèle, on observe effectivement que les résidus sont distribués de manière aléatoire autour de 0. Il n'y a aucun

motif clair qui se dégage. L'hypothèse d'homoscédasticité tient et on peut donc conclure que les hypothèses de la régression linéaire sont respectées pour le modèle 6.

L'analyse des valeurs influentes a été réalisée avec la distance de Cook. Bien que quelques observations dépassent le seuil relatif ($4/369 = 0.011$), aucune observation ne s'approche du seuil critique absolu de 1 (le maximum observé sur le graphique des distances de Cook étant d'environ 0.04). Par conséquent, aucune observation n'influence suffisamment la droite de régression pour justifier son exclusion. Ce qui confirme la robustesse de l'ajustement aux données globales.



7 - Distances de Cook

6. INTERPRÉTATION ET CONCLUSION

Notre objectif était d'expliquer la distribution des œufs de maquereau à partir des facteurs environnementaux disponibles. La variable réponse *egg.dens* a été transformée en $\log(\text{egg.dens})$ afin de stabiliser la variance et corriger la forte asymétrie observée. Le modèle final retenu est :

$$\log(\text{egg.dens}) = 8.433 + 0.413 \cdot \log(\text{b.depth}) - 0.180(\text{lat}) - 0.211(\text{lon}) - 0.793(\text{c.dist})$$

Ce modèle a été sélectionné pour son respect des hypothèses de la régression linéaire ($\text{VIF} < 3$, résidus approximativement normaux, homoscédasticité vérifiée), au détriment d'un pouvoir explicatif légèrement plus faible ($R^2_{\text{ajusté}} = 0.301$).

Les quatre variables retenues sont toutes significatives à $\alpha = 0.05$.

La profondeur du fond marin ($\log(\text{b.depth})$) est associée positivement à la densité d'œufs : une augmentation de 1% de la profondeur correspond à une hausse de 0.413% de la densité, ce qui laisse savoir que la densité des œufs de maquereau augmente davantage dans les zones plus profondes. La latitude et la longitude ont toutes deux un effet négatif : la densité semble diminuer lorsqu'on se déplace vers le nord ou vers l'est de la zone étudiée, ce qui reflète la distribution géographique préférentielle du stock reproducteur. Enfin, la distance au contour des 200m (*c.dist*) a un effet négatif marqué : plus un site est éloigné de la zone côtière des 200m, plus la densité d'œufs est faible ce qui montre que la distance au contour des 200m est un facteur clé dans la distribution spatiale des œufs de maquereau.

Sur le plan mathématique, les diagnostics ont confirmé la validité du modèle : les résidus suivent une distribution normale, l'hypothèse d'homoscédasticité est respectée, et aucune observation aberrante n'influence indûment l'ajustement (distance de Cook maximale < 1).

Le modèle explique environ 30% de la variabilité de $\log(\text{egg.dens})$, ce qui est modéré. Une part importante de la variabilité reste inexpliquée, possiblement due à des facteurs non mesurés. Une suggestion pour une future analyse serait de mesurer d'autres facteurs comme la force du courant d'eau dans les zones étudiées qui affecte possiblement la densité.